Analiza UFC borbi

SAP MATER

```
# Potrebni paket i učitavanje dataseta
library(dplyr)
##
## Attaching package: 'dplyr'
## The following objects are masked from 'package:stats':
##
##
       filter, lag
## The following objects are masked from 'package:base':
##
##
       intersect, setdiff, setequal, union
fights = read.csv("./total_fight_data.csv")
fighters = read.csv("./fighter details.csv")
RBData = read.csv("./preprocessed data.csv")
                                              # Data just about red and blue fighters
```

Case study: UFC borbe

Analiza sportskih događaja (utakmica, mečeva, borbi...) kao i performansi pojedinih sportaša zadire u pore svakog dijela sportske industrije (menadžment, trening, sponzorstvo, marketing i sportske prognoze). Iz tog razloga se već duži niz godina prikupljaju podatci Ultimate Fighting Championship (UFC) borbi.

Prikupljeni podatci predstavljaju informacije o UFC borbama (i borcima koji su u njima sudjelovali) u razdoblju od 1993. - 2021. godine. Borbama su pridodane značajke poput trajanja u rundama, sudca borbe te datuma i lokacije održavanja, dok su borcima pridružene značajke kao što su visina, težine, dužina ruke ili stav borca. Dodatno je poznat i pobjednik svake borbe (i način pobjede). U nastavku se nalaze istraživača pitanja na koja će biti dani odgovori.

Općenita deskriptivna analiza

Varijable podataka su sljedeće:

names(fights)

```
"R_KD"
                                                                  "B KD"
    [1] "R_fighter"
                           "B_fighter"
##
    [5] "R SIG STR."
                           "B SIG STR."
                                               "R SIG STR pct"
                                                                  "B SIG STR pct"
##
   [9] "R TOTAL STR."
                           "B TOTAL STR."
                                               "R TD"
                                                                  "B TD"
## [13] "R TD pct"
                           "B_TD_pct"
                                               "R SUB ATT"
                                                                  "B SUB ATT"
## [17] "R_REV"
                           "B REV"
                                               "R CTRL"
                                                                  "B CTRL"
## [21] "R_HEAD"
                           "B HEAD"
                                               "R BODY"
                                                                  "B BODY"
                           "B_LEG"
  [25] "R LEG"
                                               "R DISTANCE"
                                                                  "B DISTANCE"
   [29] "R_CLINCH"
                           "B CLINCH"
                                               "R GROUND"
                                                                  "B GROUND"
        "win by"
                           "last round"
                                               "last round time" "Format"
## [37] "Referee"
                           "Date"
                                               "Year"
                                                                  "City"
```

```
## [41] "State"
                           "Country"
                                             "Fight_type"
                                                                "Winner"
total_fight = left_join(fights, fighters, by = c(R_fighter = "fighter_name"))
total_fight <- total_fight %>%
    rename(R_Height = "Height", R_Weight = "Weight", R_Reach = "Reach",
        R_Stance = "Stance", R_DOB = "DOB", R_SLpM = "SLpM",
        R_Str_Acc = "Str_Acc", R_SApM = "SApM", R_Str_Def = "Str_Def",
        R_TD_Avg = "TD_Avg", R_TD_Acc = "TD_Acc", R_TD_Def = "TD_Def",
        R Sub Avg = "Sub Avg")
total_fight = left_join(total_fight, fighters, by = c(B_fighter = "fighter_name"))
total fight <- total fight %>%
    rename(B_Height = "Height", B_Weight = "Weight", B_Reach = "Reach",
        B_Stance = "Stance", B_DOB = "DOB", B_SLpM = "SLpM",
        B Str Acc = "Str Acc", B SApM = "SApM", B Str Def = "Str Def",
        B_TD_Avg = "TD_Avg", B_TD_Acc = "TD_Acc", B_TD_Def = "TD_Def",
        B_Sub_Avg = "Sub_Avg")
names(total_fight)
    [1] "R_fighter"
                           "B_fighter"
                                             "R_KD"
                                                                "B KD"
##
    [5] "R_SIG_STR."
                           "B_SIG_STR."
                                             "R_SIG_STR_pct"
                                                                "B_SIG_STR_pct"
                           "B_TOTAL_STR."
                                             "R TD"
                                                                "B TD"
   [9] "R_TOTAL_STR."
                                             "R_SUB_ATT"
                                                                "B SUB ATT"
## [13] "R_TD_pct"
                           "B_TD_pct"
                                             "R_CTRL"
## [17] "R REV"
                           "B REV"
                                                                "B CTRL"
## [21] "R HEAD"
                           "B HEAD"
                                             "R BODY"
                                                                "B BODY"
                           "B LEG"
                                             "R_DISTANCE"
                                                                "B DISTANCE"
## [25] "R_LEG"
## [29] "R_CLINCH"
                           "B CLINCH"
                                             "R GROUND"
                                                                "B GROUND"
## [33] "win by"
                           "last round"
                                             "last round time" "Format"
## [37] "Referee"
                           "Date"
                                             "Year"
                                                                "City"
## [41] "State"
                                             "Fight_type"
                                                                "Winner"
                           "Country"
## [45] "R Height"
                           "R Weight"
                                             "R Reach"
                                                                "R Stance"
## [49] "R_DOB"
                           "R_SLpM"
                                             "R_Str_Acc"
                                                                "R SApM"
## [53] "R_Str_Def"
                           "R_TD_Avg"
                                             "R_TD_Acc"
                                                                "R_TD_Def"
                           "B_Height"
                                             "B_Weight"
                                                                "B Reach"
## [57] "R_Sub_Avg"
  [61] "B Stance"
                           "B DOB"
                                             "B SLpM"
                                                                "B Str Acc"
                                             "B_TD_Avg"
                                                                "B_TD_Acc"
## [65] "B_SApM"
                           "B_Str_Def"
## [69] "B_TD_Def"
                           "B_Sub_Avg"
```

Neke od važnijih varijabli su winner (pobjednik borbe koji može biti R - red ili B - blue ovisno o kutu), win_by (način pobjede, može biti KO/TKO, medicinski TKO...), težinska kategorija boraca (heavyweight, strawweight, featherweight...), itd...

Naizgled nam sve varijable daju korisne informacije i statistički su relevantne, stoga za sada neće biti uklonjena niti jedna varijabla.

Q-Q diagram za najvažnije varijable

Možda koji histogram za najvažnije podatke

Box plot za najvažnije podatke

```
Class :character
                       Class :character
                                           1st Qu.:0.0000
                                                             1st Qu.:0.0000
##
    Mode :character
                       Mode :character
                                           Median :0.0000
                                                            Median : 0.0000
                                                                  :0.1798
##
                                           Mean :0.2498
                                                             Mean
##
                                           3rd Qu.:0.0000
                                                             3rd Qu.:0.0000
##
                                           Max.
                                                  :5.0000
                                                            Max.
                                                                    :4.0000
##
    R SIG STR.
                        B SIG STR.
                                           R SIG STR pct
                                                               B SIG STR pct
   Length:6012
                       Length:6012
                                           Length:6012
                                                               Length:6012
##
    Class : character
                       Class : character
                                           Class : character
                                                               Class : character
##
##
    Mode :character
                       Mode :character
                                           Mode :character
                                                               Mode :character
##
##
##
  R_TOTAL_STR.
                       B_TOTAL_STR.
                                               R_TD
                                                                   B_TD
##
##
   Length:6012
                       Length:6012
                                           Length:6012
                                                               Length:6012
##
    Class :character
                       Class :character
                                           Class : character
                                                               Class : character
##
    Mode :character
                       Mode :character
                                           Mode :character
                                                               Mode :character
##
##
##
##
      R TD pct
                         B TD pct
                                             R SUB ATT
                                                                B SUB ATT
   Length:6012
##
                       Length:6012
                                           Min. : 0.0000
                                                             Min.
                                                                     :0.000
    Class : character
                       Class : character
                                           1st Qu.: 0.0000
                                                              1st Qu.:0.000
   Mode :character
                       Mode :character
                                           Median : 0.0000
##
                                                              Median :0.000
##
                                           Mean : 0.4814
                                                              Mean
                                                                     :0.344
##
                                           3rd Qu.: 1.0000
                                                              3rd Qu.:0.000
##
                                           Max.
                                                  :10.0000
                                                              Max.
                                                                     :7.000
##
        R_REV
                         B_REV
                                          R_CTRL
                                                              B_CTRL
           :0.0000
                             :0.0000
                                       Length:6012
                                                           Length:6012
##
    Min.
                     Min.
    1st Qu.:0.0000
                     1st Qu.:0.0000
                                       Class : character
                                                           Class : character
    Median :0.0000
                     Median :0.0000
                                       Mode :character
                                                           Mode :character
##
    Mean
         :0.1377
                     Mean
                             :0.1354
##
    3rd Qu.:0.0000
                     3rd Qu.:0.0000
##
    Max. :5.0000
                     Max.
                            :3.0000
       R_HEAD
##
                                              R_BODY
                                                                  B_BODY
                          B_{\text{HEAD}}
##
    Length:6012
                       Length:6012
                                           Length:6012
                                                               Length: 6012
##
    Class : character
                       Class : character
                                           Class : character
                                                               Class : character
##
    Mode :character
                       Mode :character
                                           Mode :character
                                                               Mode : character
##
##
##
##
       R LEG
                          B LEG
                                            R DISTANCE
                                                                B DISTANCE
##
   Length:6012
                       Length:6012
                                           Length:6012
                                                               Length: 6012
    Class : character
                       Class : character
                                           Class : character
                                                               Class : character
##
    Mode :character
                       Mode :character
                                           Mode :character
                                                               Mode : character
##
##
##
##
      R_CLINCH
                         B_CLINCH
                                             R_{GROUND}
                                                                 B_GROUND
   Length:6012
                       Length:6012
                                           Length:6012
                                                               Length:6012
##
    Class : character
                       Class : character
                                           Class : character
                                                               Class : character
##
    Mode :character
                       Mode :character
                                           Mode :character
                                                               Mode : character
##
##
```

##

## ## ## ## ##	win_by Length:6012 Class :character Mode :character	Min. :1.000 1 1st Qu.:1.000	Class :character	Format Length:6012 Class :character Mode :character
##	Referee	Date	Year	City
##	Length:6012	Length:6012	Min. :1994 L	ength:6012
##	Class :character	Class :character	•	Class :character
##	Mode :character	Mode :character		<pre>fode :character</pre>
##			Mean :2013	
## ##			3rd Qu.:2018 Max. :2021	
##	State	Country	Fight_type	Winner
##	Length: 6012	Length: 6012	Length: 6012	Length: 6012
##	Class :character	Class : character		
##	Mode :character	Mode :character	Mode :character	Mode :character
##				
##				
##	D Haimbe	D Haimba	D. Danah	D. Chamas
## ##	R_Height Length:6012	R_Weight Length:6012	R_Reach Length:6012	R_Stance Length:6012
##	Class : character	Class : character		•
##	Mode :character	Mode : character		
##				
##				
##				
##	R_DOB	R_SLpM	R_Str_Acc	R_SApM
## ##	Length:6012 Class:character	Min. : 0.000 1st Qu.: 2.420	Length:6012 Class :character	Min. : 0.000 1st Qu.: 2.340
##	Mode : character	Median : 3.130	Mode : character	Median : 2.980
##	nodo londractor	Mean : 3.224	Tious Fondius	Mean : 3.088
##		3rd Qu.: 3.940		3rd Qu.: 3.750
##		Max. :19.910		Max. :23.330
##	R_Str_Def	R_TD_Avg	R_TD_Acc	R_TD_Def
##	Length: 6012	Min. : 0.000	Length: 6012	Length: 6012
##	Class : character	1st Qu.: 0.640	Class :character	Class :character
## ##	Mode :character	Median : 1.370 Mean : 1.625	Mode :character	Mode :character
##		3rd Qu.: 2.380		
##		Max. :14.190		
##	R_Sub_Avg	B_Height	B_Weight	B_Reach
##	Min. : 0.0000	Length:6012	Length:6012	Length:6012
##	1st Qu.: 0.1000	Class : character	Class :character	
##	Median : 0.5000	Mode :character	Mode :character	Mode :character
##	Mean : 0.6889			
## ##	3rd Qu.: 1.0000 Max. :21.9000			
##	B_Stance	B_DOB	B_SLpM	B_Str_Acc
##			-	
	Length:6012	Length:6012	Min. : 0.000	Length:6012
##	Length:6012 Class :character	Length:6012 Class :character		Length:6012 Class :character

```
##
                                             3rd Qu.: 3.880
##
                                             Max.
                                                     :15.070
##
        B SApM
                      B Str Def
                                             B TD Avg
                                                              B_TD_Acc
           : 0.00
                     Length: 6012
                                                 : 0.000
                                                            Length:6012
##
    Min.
                                          Min.
##
    1st Qu.: 2.45
                     Class : character
                                          1st Qu.: 0.480
                                                            Class : character
    Median: 3.07
                     Mode
                           :character
                                          Median: 1.190
                                                            Mode
                                                                  :character
##
##
    Mean
           : 3.26
                                          Mean
                                                 : 1.462
    3rd Qu.: 3.90
##
                                          3rd Qu.: 2.160
##
    Max.
            :22.50
                                          Max.
                                                 :13.950
##
      B_TD_Def
                           B_Sub_Avg
##
    Length: 6012
                        Min.
                                : 0.0000
                         1st Qu.: 0.0000
    Class : character
##
##
    Mode
         :character
                         Median: 0.4000
##
                        Mean
                                : 0.6469
##
                         3rd Qu.: 0.9000
##
                         Max.
                                :16.4000
```

Iz ovog je vidljivo da postoje outlieri koji će najvjerojatnije biti izbačeni u nekom trenutku analize (npr. B_total_time_fought.seconds gdje je minimalna vrijednost 7, iako relevantna, informacija je preveliki outlier ako ju usporedimo sa medijanom ili srednjom vrijednošću).

sapply(fights, class)

```
##
                                                                               R_SIG_STR.
          R_fighter
                           B_fighter
                                                   R_KD
                                                                    B_KD
##
       "character"
                         "character"
                                             "integer"
                                                               "integer"
                                                                               "character"
                                                                             B_TOTAL_STR.
##
        B_SIG_STR.
                       R_SIG_STR_pct
                                         B_SIG_STR_pct
                                                            R_TOTAL_STR.
##
       "character"
                                                             "character"
                                                                               "character"
                          "character"
                                           "character"
##
               R TD
                                              R_TD_pct
                                                                B_TD_pct
                                                                                 R SUB ATT
                                 B_TD
##
       "character"
                          "character"
                                           "character"
                                                             "character"
                                                                                 "integer"
##
          B SUB ATT
                                R_REV
                                                  B_REV
                                                                  R_CTRL
                                                                                    B CTRL
##
          "integer"
                            "integer"
                                             "integer"
                                                             "character"
                                                                               "character"
##
                                                 R_BODY
             R_{\text{HEAD}}
                               B_HEAD
                                                                  B_BODY
                                                                                     R_LEG
##
       "character"
                         "character"
                                           "character"
                                                             "character"
                                                                               "character"
              B LEG
                          R_DISTANCE
                                            B_DISTANCE
##
                                                                R_CLINCH
                                                                                  B_CLINCH
##
       "character"
                          "character"
                                           "character"
                                                             "character"
                                                                               "character"
##
           R_{GROUND}
                             B_GROUND
                                                 win_by
                                                              last_round last_round_time
##
       "character"
                          "character"
                                           "character"
                                                               "integer"
                                                                               "character"
##
             Format
                              Referee
                                                   Date
                                                                     Year
                                                                                      City
##
       "character"
                          "character"
                                           "character"
                                                               "integer"
                                                                               "character"
                                            Fight_type
##
              State
                              Country
                                                                  Winner
##
       "character"
                         "character"
                                           "character"
                                                             "character"
```

Možemo vidjeti da je su podatci većinski sastavljeni od cijelih i decimalnih brojeva, te postoji nekoliko varijabli sa tekstualnim vrijednostima.

Pretraživanje dataseta za nedostajuće podatke:

Iz prethodnog je vidljivo da varijable R_Reach i B_Reach imaju nedostajućih podataka. Pošto su iste kasnije potrebne u testiranju, te ih stoga nećemo ukloniti, već će biti profiltrirane prije nego li će se koristiti

za testiranje.

```
## Broj nedostajućih vrijednosti za varijablu Referee : 32
## Broj nedostajućih vrijednosti za varijablu Winner : 618
## Broj nedostajućih vrijednosti za varijablu R_Height : 4
## Broj nedostajućih vrijednosti za varijablu R_Weight : 2
## Broj nedostajućih vrijednosti za varijablu R_Reach : 406
## Broj nedostajućih vrijednosti za varijablu R_Stance : 29
## Broj nedostajućih vrijednosti za varijablu R_DOB : 63
## Broj nedostajućih vrijednosti za varijablu B_Height : 10
## Broj nedostajućih vrijednosti za varijablu B_Weight : 8
## Broj nedostajućih vrijednosti za varijablu B_Reach : 891
## Broj nedostajućih vrijednosti za varijablu B_Stance : 66
## Broj nedostajućih vrijednosti za varijablu B_Stance : 66
## Broj nedostajućih vrijednosti za varijablu B_DOB : 172
```

Nadalje ispis iznad također pokazuje varijable sa nedostajućim podatcima, te kao i u prethodnom slučaju, ovi podatci će biti profiltrirani ovisno o potrebi.

Pitanje 1:

[1] 70 74 75 63 68 75

Možemo li očekivati završetak borbe nokautom ovisno o razlici u dužini ruku između boraca?

Odabir metode Ovo pitanje možemo preformulirati kao: *Postoji li zavisnost između razlike u dužini ruku boraca i završetka borbe nokautom?*

Pa tako možemo postaviti i pitanje: Postoji li nezavisnost između razlike u dužini ruku boraca i završetka borbe nokautom?

Prema ovim pitanjima moglo bi se zaključiti da bi trebalo provesti test nezavisnosti, no ključna informacija je da obje varijable nisu kategorijeske - razlika duljine ruku između boraca je kvantitativna varijabla, dok je ishod borbe kategorijska varijabla. Iz tog razloga test nezavisnosti nije valjana opcija za dobivanje odgovora na ovo pitanje.

Pošto test nezavisnosti nije dobra opcija, druga metoda kojom bi se moglo doći do odgovora na ovo pitanje je **analiza varijance**. Imajući samo jednu nezavisnu varijablu (razlika duljine ruku između boraca) riječ je o jednofaktorskoj analizi varijance.

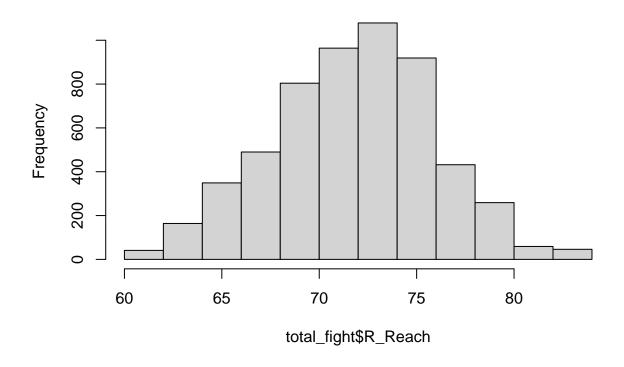
```
head(total_fight$B_Weight)

## [1] "135 lbs." "205 lbs." "241 lbs." "115 lbs." "135 lbs." "145 lbs."

total_fight$R_Reach = strtoi(substr(total_fight$R_Reach, 1, 2))

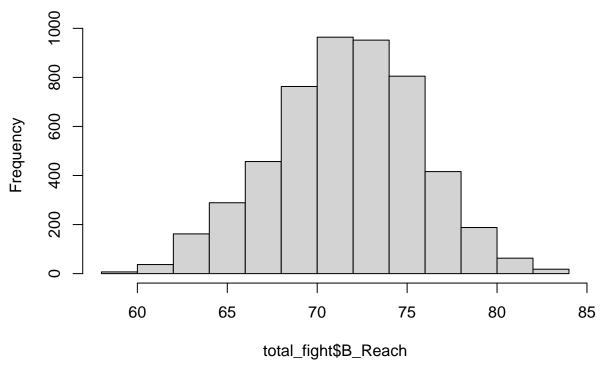
total_fight$B_Reach = strtoi(substr(total_fight$B_Reach, 1, 2))
head(total_fight$R_Reach)
```

Histogram of total_fight\$R_Reach



hist(total_fight\$B_Reach)





$\mathbf{U}\mathbf{vod}$

Filtriranje podataka Pošto smo već prije uočili da u ovim varijablama postoje objekti koji nemaju vrijednosti, prije nego li počnemo raditi s njima, podatci će prvo biti profiltrirani kako bi se nezadovoljavajući objekti uklonili:

```
##
       B_Reach R_Reach
## 1
            67
                      70
## 2
            76
                      74
## 3
            75
                      75
## 4
            61
                      63
## 5
            72
                      68
## 6
            72
                      75
## 7
            76
                      71
                      77
## 8
            81
## 9
            70
                      75
## 11
            66
                      68
            79
## 12
                      77
## 13
            72
                      74
## 14
            71
                      69
## 15
            74
                      75
## 16
            69
                      64
```

```
70
## 17
           69
## 18
           66
                    71
## 19
           70
                    72
           67
                    67
## 20
           70
                    75
# provjera za razliku duljine ruku
for (name in names(arm_lengths)) {
    if (sum(is.na(arm_lengths[, name])) > 0) {
        cat("Broj nedostajućih vrijednosti za varijablu ", name,
            ": ", sum(is.na(arm_lengths[, name])), "\n")
    }
}
win_methods <- select(total_fight, c("B_Reach", "R_Reach", "win_by"))</pre>
win_methods <- win_methods[rowSums(is.na(win_methods)) == 0,</pre>
win_methods <- select(win_methods, c("win_by"))</pre>
win_methods <- win_methods$win_by</pre>
win_methods[0:21]
    [1] "KO/TKO"
                                "Decision - Unanimous" "KO/TKO"
    [4] "Decision - Unanimous" "Decision - Unanimous" "KO/TKO"
##
                                "Decision - Unanimous" "KO/TKO"
##
    [7] "KO/TKO"
## [10] "Decision - Split"
                                "KO/TKO"
                                                         "Could Not Continue"
## [13] "KO/TKO"
                                "Could Not Continue"
                                                         "Decision - Unanimous"
                                                         "Decision - Unanimous"
## [16] "KO/TKO"
                                "KO/TKO"
## [19] "Decision - Split"
                                "KO/TKO"
                                                         "Submission"
# provjera za razlog pobjede
for (name in names(win_methods)) {
    if (sum(is.na(win_methods[, name])) > 0) {
        cat("Broj nedostajućih vrijednosti za varijablu ", name,
            ": ", sum(is.na(win_methods[, name])), "\n")
    }
}
```

Pošto nema ispisa možemo zaključiti da su svi nezadovoljavajući objekti uklonjeni.

Sada možemo nastaviti raditi sa podatcima.

Pretpostavke

Kod provođenja testa moramo provijeriti zadovoljavaju li naši podatci preduvjete potrebne za provođenje izabrane metode. Pošto smo za odgovor na ovo pitanje odlučili provesti jednofaktorsku analizu varijance, preduvjeti su sljedeći:

Test se provodi na podatcima koji su slučajno izabrani iz populacije Koristi se pretpostavka da su podatci na kojima se provode testovi slučajno izabrani iz populacije

Zavisna kvantitativna varijabla mora pratiti normalnu distribuciju Apsolutna razlika dužine ruku boraca (B_Reach - R_Reach) je u ovom slučaju zavisna kvantitativna varijabla, te ćemo provjeriti zadovoljava li pretpostavku:

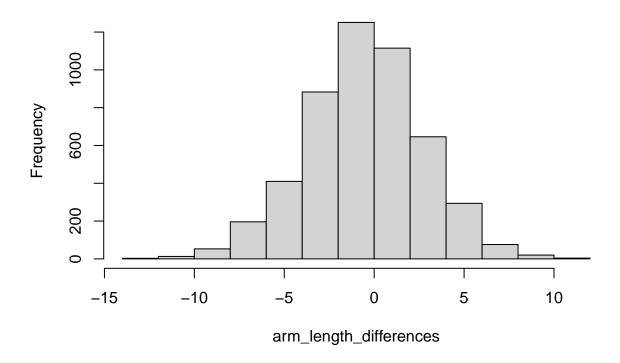
```
arm_length_differences <- (arm_lengths$B_Reach - arm_lengths$R_Reach)
arm_length_differences[0:76]</pre>
```

```
5
                                      -5
   [26]
          2
                     3
                                       7
                                         -6
                                              1
                                                 1
                                                     3
                                                            0
##
                 2
                        0
                            3
                                2
                                   2
                                                       -2
                                                               -2
                                                                   3
                                                                       0
                                                                             -2
                                                                                 2
                                                                                    -4
                                                                                         0
                                                                                           -2 -1
          2
                                          3 -3 -5 -3
                                                                2
   [51]
                                                           -4
                                                                              3 -8
   [76]
         -5
##
```

Možemo uočiti da su razlike duljina ruku cijeli brojevi, što je pomalo neočekivano, no razlog tomu je što su početne vrijednosti bile u mjernoj jedinici *inch*, te će tako ostati do završnog rezultata kako bi se očuvala točnost podataka. Pošto je sada sve u redu, možemo početi sa ispitivanjem normalnosti ove varijable. Jedan od najlakših i najefikasnijih načina provjere normalnosti je histogram.

hist(arm_length_differences, main = "Arm length difference between fighters")

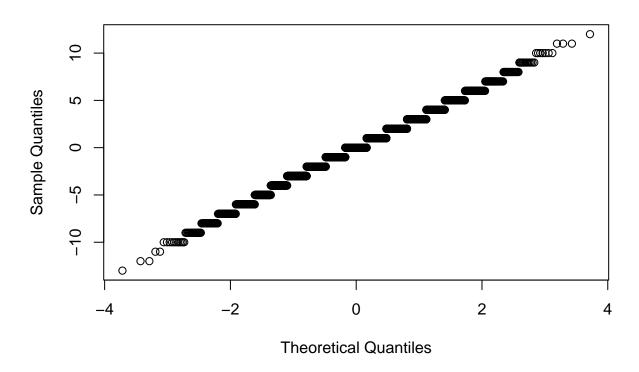
Arm length difference between fighters



Iz histograma možemo zaključiti da su podatci relativno lijepo raspoređeni po normalnoj distribuciji. Kao još jedan dijagnostički alat, možemo napraviti i Q-Q plot.

qqnorm(arm_length_differences)

Normal Q-Q Plot



Kao što možemo vidjeti, Q-Q plot također daje poprilično dobre indikacije da se radi o normalnoj distribuciji. Kao konačnu potvrdu naše pretpostavke, koristiti ćemo Lillieforsov test:

require(nortest)

```
## Loading required package: nortest
lillie.test(arm_length_differences)

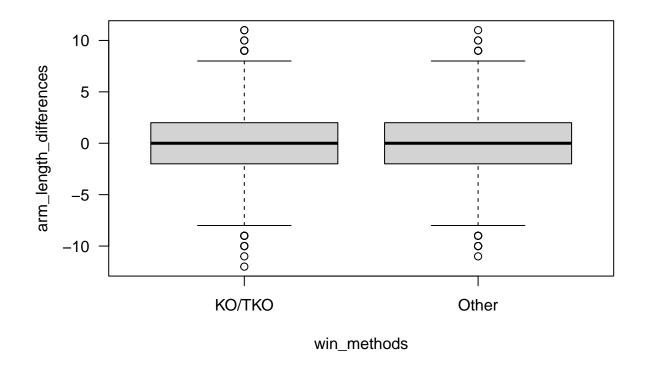
##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: arm_length_differences
## D = 0.073975, p-value < 2.2e-16
lillie.test(sample(arm_length_differences, size = 100))

##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: sample(arm_length_differences, size = 100)
## D = 0.11653, p-value = 0.001919</pre>
```

Prema rezultatima Lillieforsovog testa možemo zaključiti da podatci nisu normalno distribuirani, obrnuto od naše pretpostavke, no moramo uzeti u obzir da niti Lillieforsov test ne daje sigurnost u distribuciju podataka, pošto što je skup podataka veći, to je test osjetljiviji na normalnost istih podataka. Stoga ćemo se oslanjati na robusnost ANOVA-e na normalnost pri grupama iste veličine.

Homogenost varijance u svim grupama (homoskedastičnost) Homogenost varijance kroz grupe inicijalno možemo provjeriti boxplotom:

```
question_1_data <- data.frame(arm_length_differences, win_methods)</pre>
# stvaranje dviju grupa u nezavisnoj kategorijskoj
# varijabli
question_1_data$win_methods <- replace(question_1_data$win_methods,</pre>
    question_1_data$win_methods != "KO/TKO", "Other")
# length(question 1 data$win methods[question 1 data$win methods
# == 'KO/TKO'1)
{\it \# length (question\_1\_data\$win\_methods[question\_1\_data\$win\_methods]}
# != 'KO/TKO']) nasumično uzimanje uzorka kako bi se
# stvorile grupe iste veličine za reproducibilnost
set.seed(8919)
other <- sample_n(tbl = question_1_data[question_1_data$win_methods !=
    "KO/TKO", ], size = 1533)
KO <- question_1_data[question_1_data$win_methods == "KO/TKO",</pre>
# grupe iste veličine
question_1_data <- rbind(KO, other)</pre>
question_1_data[0:10, ]
##
      arm_length_differences win_methods
## 1
                                   KO/TKO
                           -3
                                   KO/TKO
## 3
                            0
## 6
                           -3
                                   KO/TKO
## 7
                            5
                                   KO/TKO
## 9
                           -5
                                   KO/TKO
## 11
                            2
                                   KO/TKO
## 13
                            2
                                   KO/TKO
                           -1
                                   KO/TKO
## 16
## 17
                           -5
                                   KO/TKO
                           -5
                                   KO/TKO
## 20
boxplot(arm_length_differences ~ win_methods, data = question_1_data,
  las = 1)
```



Iz boxplota možemo zaključiti da varijanca gotovo ne odstupa ovisno o razlogu pobjede, stoga smatramo da je i ovaj preduvjet za provedbu analize varijance zadovoljen. Također, možemo vidjeti kako se srednje vrijednosti ovisno o vrijednosti kategorijske varijable skoro pa ne razlikuju, što nam govori da vjerojatno nećemo imati dovoljno dokaza za odbacivanje hipoteze H0 u korist hipoteze H1.

Kao potvrdu o hipotezi za jednakost varijance napraviti ćemo Bartlettov test:

[1] 10.34751

U vidu dobivenih rezultata iz Bartlettovog testa ne možemo odbaciti hipotezu H0 u korist hipoteze H1 na razini signifikantnosti 0.05, drugim riječima - imamo indikacije da su varijance grupa jednake, te s time da je

preduvjet homoskedastičnosti zadovoljen.

Pošto su svi preduvjeti zadovoljeni, možemo početi sa provođenjem testiranje.

Testiranje

Provodimo jednofaktorski ANOVA test:

Hipoteze

Hipoteza H0: srednje vrijednosti obiju grupa su iste

```
Hipoteza H1: srednje vrijednost grupa su različite
##
          KO/TKO
## KO/TKO
               0
## Other
               1
result <- aov(question_1_data$arm_length_differences ~ question_1_data$win_methods)
summary(result)
##
                                 Df Sum Sq Mean Sq F value Pr(>F)
                                                     0.044 0.834
## question_1_data$win_methods
                                  1
                                             0.471
## Residuals
                               3064 32653 10.657
model <- lm(question_1_data$arm_length_differences ~ question_1_data$win_methods)</pre>
summary(model)
##
## Call:
## lm(formula = question_1_data$arm_length_differences ~ question_1_data$win_methods)
##
## Residuals:
##
       Min
                       Median
                                    3Q
                                            Max
                  1Q
## -11.8565 -1.8813 0.1187 2.1187 11.1435
##
## Coefficients:
##
                                     Estimate Std. Error t value Pr(>|t|)
## (Intercept)
                                     -0.14351
                                                 0.08338 -1.721
                                                                   0.0853 .
## question_1_data$win_methodsKO/TKO 0.02479
                                                                   0.8335
                                                 0.11791
                                                           0.210
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
```

```
##
## Residual standard error: 3.264 on 3064 degrees of freedom
## Multiple R-squared: 1.442e-05, Adjusted R-squared: -0.0003119
## F-statistic: 0.04419 on 1 and 3064 DF, p-value: 0.8335
anova(model)

## Analysis of Variance Table
##
## Response: question_1_data$arm_length_differences
##
## Df Sum Sq Mean Sq F value Pr(>F)
## question_1_data$win_methods 1 0 0.471 0.0442 0.8335
## Residuals 3064 32653 10.657
```

Zaključak

U vidu dobivenih dokaza, ne možemo odbaciti hipotezu H0 u korist hipoteze H1 na razini signifikantnosti 0.05.

Odgovor na početno pitanje bi glasio:

"Ne, ne možemo očekivati završetak borbe nokautom ovisno o razlici duljine ruku boraca"

Pitanje 2:

Razlikuje li se trajanje mečeva (u sekundama) između pojedinih kategorija?

Prije nego što možemo odgovoriti na to pitanje, trebamo izvući sve podatke iz dataseta u odgovarajućem formatu.

```
# adding total time fought in seconds
library(stringr)
last_round_vector = stringr::str_split_fixed(fights$last_round_time,
    pattern = ":", 2)
fights <- cbind(fights, total_time_in_seconds = (fights$last_round -
    1) * 5 * 60)
for (i in 1:length(fights$total_time_in_seconds)) {
    fights$total_time_in_seconds[i] = fights$total_time_in_seconds[i] +
        strtoi(last_round_vector[i], base = 10L) * 60 + strtoi((last_round_vector[i,
        ])[2], base = 10L)
# hist(fights$total_time_in_seconds)
# dividing fights by categories
beginFights <- fights %>%
    filter(grepl(paste("Women's|Strawweight|Flyweight|Bantamweight|Featherweight",
        "|Lightweight|Welterweight|Middleweight|Light Heavyweight|Heavyweight",
        sep = ""), Fight_type, ignore.case = TRUE))
beginFights <- cbind(beginFights, categories = gsub(paste("UFC | Title| Bout|",</pre>
    "Tournament | [0-9] | Interim | Super | Ultimate Fighter | [0-9] | Australia | ",
    "Brazil | Latin America | Ultimate Japan | vs. UK | UF Nations Canada vs. | T",
    sep = ""), "", beginFights$Fight_type))
beginFights$categories <- trimws(beginFights$categories)</pre>
# all categories
validFights = beginFights
```

```
validFights$categories = factor(validFights$categories, levels = c("Women's Strawweight",
    "Women's Flyweight", "Women's Bantamweight", "Women's Featherweight",
    "Flyweight", "Bantamweight", "Featherweight", "Lightweight",
    "Welterweight", "Middleweight", "Light Heavyweight", "Heavyweight"),
    labels = c("womensStrawweight", "womensFlyweight", "womensBantamweight",
        "womensFeatherweight", "Flyweight", "Bantamweight", "Featherweight",
        "Lightweight", "Welterweight", "Middleweight", "LightHeavyweight",
        "Heavyweight"))
```

Raspodjela podataka po kategorijama

summary(validFights\$categories)

##	womensStrawweight	womensFlyweight	${\tt womensBantamweight}$	${\tt womensFeatherweight}$
##	175	103	141	16
##	${ t Flyweight}$	Bantamweight	Featherweight	Lightweight
##	208	431	478	1014
##	Welterweight	Middleweight	LightHeavyweight	Heavyweight
##	984	751	526	541

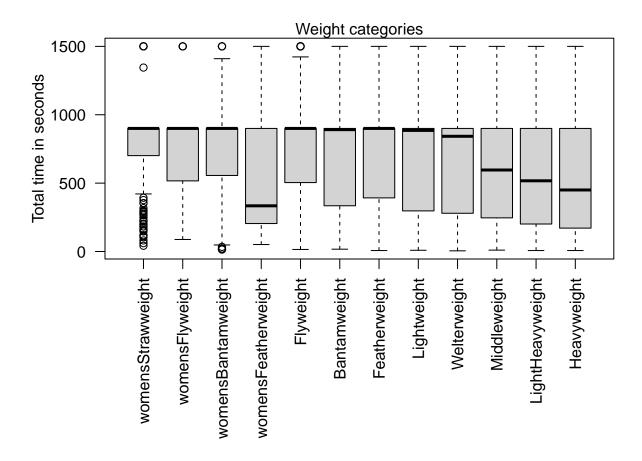
Sažetak trajanja borbi u sekundama

```
summary(validFights$total_time_in_seconds)
```

```
## Min. 1st Qu. Median Mean 3rd Qu. Max.
## 5.0 273.0 782.0 626.4 900.0 1500.0
```

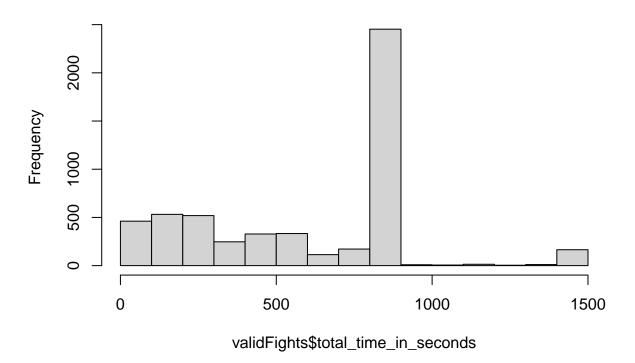
Možemo prikazati podatke u boxplotu i usporediti ih:

```
par(mar = c(10, 5, 1, 1))
boxplot(validFights$total_time_in_seconds ~ validFights$categories,
    range = 1.5, ylab = "Total time in seconds", xlab = "", las = 2)
mtext("Weight categories", side = 3)
```



Testiranje normalnosti ćemo provesti nad svim podacima, i podacima podijeljenim u grupe prema kategoriji. hist(validFights\$total_time_in_seconds)

Histogram of validFights\$total_time_in_seconds



require(nortest)
lillie.test(validFights\$total_time_in_seconds)

```
##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: validFights$total_time_in_seconds
## D = 0.24339, p-value < 2.2e-16</pre>
```

Iz histograma svih podataka i Lillieforsovog testa nad tim podacima možemo zaključiti da podaci ne prate normalnu razdiobu, ali da budemo sigurni možemo testirati i svaki zasebnu grupu podataka. Radi sažetosti, ispitivali smo samo ako je p-vrijednost bilo koje grupe veća od $\alpha=0.05$.

```
categoryLevels = levels(validFights$categories)
normalnostGrupe = FALSE
for (i in 1:length(categoryLevels)) {
    pVrijednost = lillie.test(validFights$total_time_in_seconds[validFights$categories == categoryLevels[i]])$p.value
    if (pVrijednost >= 0.05)
        normalnostGrupe = TRUE
}

if (normalnostGrupe) {
    print(noquote("Barem jedna grupa prati normalnu razdiobu."))
} else {
    print(noquote("Nijedna grupa ne prati normalnu razdiobu."))
}
```

[1] Nijedna grupa ne prati normalnu razdiobu.

Homogenost varijanci različitih populacija ćemo testirati Levenovim testom, jer je manje osjetljiv na odstupanje od normalnosti nego Bartlettov test.

```
library(car)
```

```
leveneTest(total_time_in_seconds ~ categories, validFights)
```

```
## Levene's Test for Homogeneity of Variance (center = median)
## Df F value Pr(>F)
## group 11 9.7432 < 2.2e-16 ***
## 5356
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1</pre>
```

Podaci ne zadovoljavaju ni uvjet normalnosti ni homogenosti varijanci. Kad su veličine grupa podjednake, ANOVA je relativno robusna metoda na blaga odstupanja od pretpostavke normalnosti i homogenosti varijanci ANOVA je relativno robusna metoda na blaga odstupanja od pretpostavke normalnosti i homogenosti varijanci ako su veličine grupa podjednake pa možemo uezti uzorak iz svake grupe nad kojim ćemo testirati podatke. Iz podataka vidimo da je kategorija Women's Featherweight jedan red veličine manja od drugih grupa pa nju izbacujemo iz testiranja.

```
adjustedValidFights <- beginFights %>%
    filter(!grepl("Women's Featherweight", Fight_type, ignore.case = TRUE))

adjustedValidFights$categories = factor(adjustedValidFights$categories,
    levels = c("Women's Strawweight", "Women's Flyweight", "Women's Bantamweight",
        "Flyweight", "Bantamweight", "Featherweight", "Lightweight",
        "Welterweight", "Middleweight", "Light Heavyweight",
        "Heavyweight"), labels = c("womensStrawweight", "womensFlyweight",
        "womensBantamweight", "Flyweight", "Bantamweight", "Featherweight",
        "Lightweight", "Welterweight", "Middleweight", "LightHeavyweight",
        "Heavyweight"))

adjustedValidFights <- adjustedValidFights %>%
    group_by(categories) %>%
    slice_sample(n = 100)

a = aov(adjustedValidFights$total_time_in_seconds ~ adjustedValidFights$categories)
summary(a)
```

Možemo odbaciti H0 u korist H1, time zaključujemo da postoje barem dvije grupe kojima se trajanje mečeva razlikuje.

Pitanje 3:

Traju li (u rundama) borbe za titulu duže od ostalih borbi u natjecanju? Pošto test

Radimo tablicu u kojoj je trajanje samo borbe za naslov prvaka kategorije. Takve borbe mogu trajati najviše 5 rundi.

```
bouts = select(fights, c("Fight_type", "last_round"))
# names(bouts)

titleFights <- fights %>%
    filter(grepl("title", Fight_type, ignore.case = TRUE))
# titleFights

head(select(titleFights, R_fighter, B_fighter, Fight_type, last_round, Winner))
```

```
##
                R fighter
                                   B fighter
                                                                        Fight type
## 1
                 Petr Yan Aljamain Sterling
                                                       UFC Bantamweight Title Bout
## 2
           Jan Blachowicz
                             Israel Adesanya
                                                  UFC Light Heavyweight Title Bout
## 3
             Amanda Nunes
                              Megan Anderson UFC Women's Featherweight Title Bout
             Kamaru Usman
                               Gilbert Burns
                                                       UFC Welterweight Title Bout
## 4
                              Brandon Moreno
## 5
     Deiveson Figueiredo
                                                          UFC Flyweight Title Bout
## 6 Valentina Shevchenko
                               Jennifer Maia
                                                  UFC Women's Flyweight Title Bout
##
     last_round
                               Winner
## 1
              4
                   Aljamain Sterling
              5
## 2
                       Jan Blachowicz
                         Amanda Nunes
## 3
              1
                        Kamaru Usman
              3
## 4
## 5
              5
## 6
              5 Valentina Shevchenko
```

titleFightDuration <- titleFights\$last_round #lista u koju spremamo trajanja svih title fightova

U ispisu vidimo da neki title fightovi nemaju pobjednika. Ako je borba završila u 5. rundi i nema pobjednika riječ je o Drawu, odnosno odluka sudaca je da su borci izjednačeni. Ako je borba završila prije 5. runde i nema pobjednika, što je iznimno rijetko, mora biti riječ o No Contestu, odnosno borba je prekinuta iz nekog razloga i nemoguće je odrediti pobjednika (npr. jednom je protivniku nanesen nenamjeran faul zbog kojeg ne može nastaviti borbu)

Računamo varijancu trajanja borbi koje su za naslov prvaka kategorije.

```
var(titleFightDuration)
```

[1] 2.651129

Na isti način filtriramo samo borbe koje nisu za titulu šampiona. Te borbe uvijek traju najviše 3 runde, osim ako je riječ o borbi koja je main event. Tada borba može trajati do 5 rundi. Takvih je slučajeva jako malo u usporedbi s non-title borbama koje traju do 3 runde

```
nonTitleFights <- fights %>%
    filter(!grepl("title", Fight_type, ignore.case = TRUE))
# nonTitleFights
head(select(nonTitleFights, R_fighter, B_fighter, Fight_type,
    last_round, Winner))
```

##	R_fighter	$B_fighter$	Fight	_type	last_round
## 1	Adrian Yanez	Gustavo Lopez	Bantamweight	Bout	3
## 2	Trevin Giles	Roman Dolidze	Middleweight	Bout	3
## 3	Tai Tuivasa	Harry Hunsucker	Heavyweight	Bout	1
## 4	Cheyanne Buys	Montserrat Conejo	Women's Strawweight	Bout	3
## 5	Marion Reneau	Macy Chiasson	Women's Bantamweight	Bout	3
## 6	Leonardo Santos	Grant Dawson	Lightweight	Bout	3

```
## Winner
## 1 Adrian Yanez
## 2 Trevin Giles
## 3 Tai Tuivasa
## 4 Montserrat Conejo
## 5 Macy Chiasson
## 6 Grant Dawson
```

nonTitleFightDuration <- nonTitleFights\$last_round</pre>

Računamo varijancu trajanja borbi koje nisu za naslov prvaka kategorije.

```
var(nonTitleFightDuration)
```

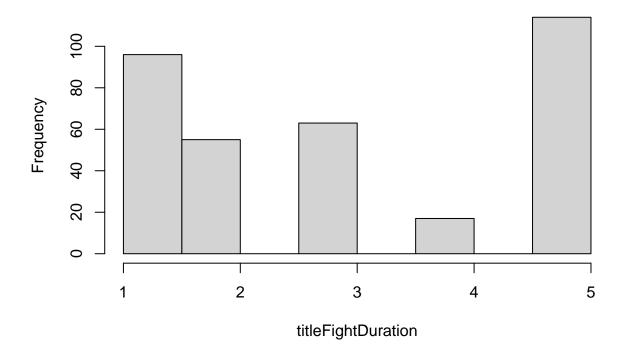
[1] 0.8879308

Vidimo da borbe koje nisu za titulu šampiona imaju puno manju varijancu, što je očekivano jer većina takvih borbi može trajati maksimalno 3 runde.

Za početak radimo Q-Q plot trajanja borbi za naslov šampiona kako bismo ustvrdili radi li se o normalnoj distribuciji

hTitleFights <- hist(titleFightDuration)

Histogram of titleFightDuration

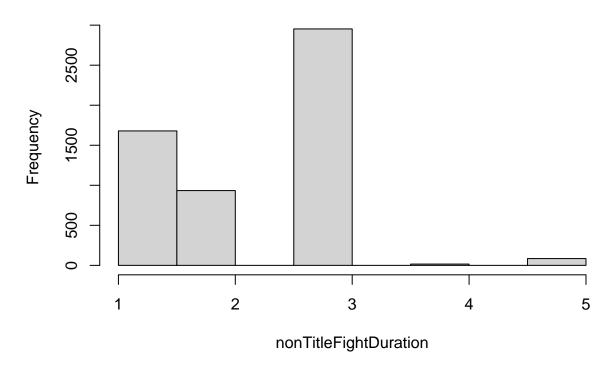


hTitleFights

```
## $breaks
## [1] 1.0 1.5 2.0 2.5 3.0 3.5 4.0 4.5 5.0
##
## $counts
```

```
## [1] 96 55
                0 63 0 17
##
## $density
## [1] 0.55652174 0.31884058 0.00000000 0.36521739 0.00000000 0.09855072 0.00000000
  [8] 0.66086957
##
##
## [1] 1.25 1.75 2.25 2.75 3.25 3.75 4.25 4.75
##
## $xname
## [1] "titleFightDuration"
## $equidist
## [1] TRUE
##
## attr(,"class")
## [1] "histogram"
hNonTitleFights <- hist(nonTitleFightDuration)
```

Histogram of nonTitleFightDuration

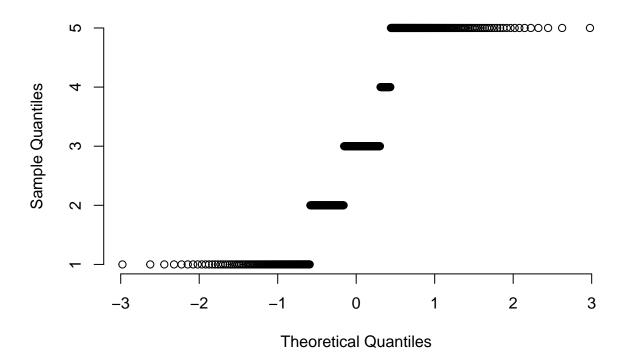


${\tt hNonTitleFights}$

```
## $breaks
## [1] 1.0 1.5 2.0 2.5 3.0 3.5 4.0 4.5 5.0
##
## $counts
## [1] 1679 934 0 2953 0 16 0 85
```

```
##
## $density
  [1] 0.592553379 0.329627669 0.000000000 1.042173990 0.000000000 0.005646727
   [7] 0.000000000 0.029998235
## $mids
## [1] 1.25 1.75 2.25 2.75 3.25 3.75 4.25 4.75
##
## $xname
## [1] "nonTitleFightDuration"
## $equidist
   [1] TRUE
##
##
## attr(,"class")
## [1] "histogram"
qqnorm(titleFightDuration, pch = 1, frame = FALSE, main = "Q-Q graf za trajanje Title fightova")
```

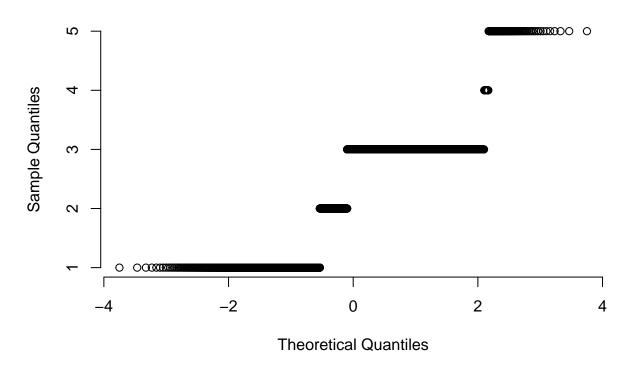
Q-Q graf za trajanje Title fightova



Vidimo da graf nimalo ne upućuje da se su trajanja borbi za titulu normalno raspodjeljena. Napravimo isti test za borbe koje nisu za naslov šampiona.

```
qqnorm(nonTitleFightDuration, pch = 1, frame = FALSE, main = "Q-Q graf za trajanje Non Title fightova")
```

Q-Q graf za trajanje Non Title fightova



Iz prethodnih grafova možemo zaključiti da trajanje niti jedne vrste borbi nema normalnu razdiobu. Pogledajmo sada kako izgledaju razdiobe na stupčastim dijagramima

```
# TO DO: dodaj bar plot sa razdiobom trajanja title fightsa
# -> koristi ggplot paket!!!
length(titleFightDuration[titleFightDuration == 5])
```

```
## [1] 114
# dodaj bar plot sa razdiobom trajanja non title fightsa
```

Još jednom vidimo da ni u jednom slučaju nije riječ o normalnoj razdiobi. Još ćemo jednom prikazati iste podatke, ali sada prikazujemo postotak svih Title fightova i Non Title fightova koji su završili u nekoj rundi, a ne konkretan broj.

```
a ne konkretan broj.

hTitleFights$counts[hTitleFights$counts != 0]

## [1] 96 55 63 17 114

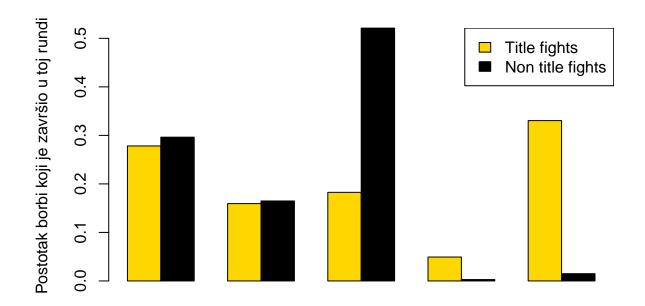
postotciZavrsetakaURundiTitle <- hTitleFights$counts[hTitleFights$counts != 0]/sum(hTitleFights$counts[hTitleFights$counts != 0])

postotciZavrsetakaURundiTitle

## [1] 0.27826087 0.15942029 0.18260870 0.04927536 0.33043478

hNonTitleFights$counts[hNonTitleFights$counts != 0]
```

[1] 1679 934 2953 16 85



Runda završetka borbe

I opet smo se uvjerili da nije ni blizu riječ o normalnoj distribuciji.

Dakle, koristimo Wilcoxon Rank-Sum Test jer je on za razliku od T-testa ne pretpostavlja normalnost.

Ali pogledajmo svejedno kakav bi rezultat dobili da koristimo T-test.

T-test H0: titleFightDuration = nonTitleFightDuration H1: titleFightDuration > nonTitleFightDuration t.test(titleFightDuration, nonTitleFightDuration, alt = "greater", var.equal = FALSE)

```
##
## Welch Two Sample t-test
##
```

Iz T-testa bi odbacili početnu hipotezu H0 da borbe za titulu šampiona u prosjeku traju jednako kao obične borbe koje nisu za titulu šampiona jer je p-vrijednost jako jako mala.

Pogledajmo sada što možemo zaključiti iz Wilcoxon Rank-Sum Testa.

```
# napravi Wilcoxon Rank-Sum Test
```

Pitati

Naslučujući da imamo podatke o cijeloj populaciji možemo napraviti Z-test pošto možemo izračunati varijancu i standardnu devijaciju, u

slučaju da nemamo pristup cijeloj populaciji, korisitit ćemo T-test za dvije populacije sa poznatim varijancama

U oba slučaja moramo provijeriti normalnost distribucije varijabli sa histogramima i Q-Q plotovima. Vjerojatno će biti potrebno odstraniti

neke podatke pošto postoje ekstremi. Run a independency test to prove independence.

Pitanje 4:

Mogu li dostupne značajke predvidjeti pobjednika? U ovom zadatku koristimo logističku regresiju jer nas zanima ako se određeni borac sam po svojim karakteristikama može svrstati u pobjetnika ili gubitnika. Kako je rezultat (zavisna varijabla) binaran, definirat ćemo ga kao Winner = 0/1;

Nakon stvaranja modela sa svim atributima vezanih uz borca i njegova protivnika lako možemo razlučiti signifikantne i nesignifikantne regresore. Ako varijabla ima p-vrijednost veću od 0.05 ne smatramo je signifikantnom za predviđanje pobjednika.

```
B_avg_opp_SIG_STR_att + B_avg_opp_SIG_STR_landed + B_avg_TOTAL_STR_att +
   B_avg_TOTAL_STR_landed + B_avg_opp_TOTAL_STR_att + B_avg_opp_TOTAL_STR_landed +
   B_avg_TD_att + B_avg_TD_landed + B_avg_opp_TD_att + B_avg_opp_TD_landed +
   B_avg_HEAD_att + B_avg_HEAD_landed + B_avg_opp_HEAD_att +
    B_avg_opp_HEAD_landed + B_avg_BODY_att + B_avg_BODY_landed +
   B_avg_opp_BODY_att + B_avg_opp_BODY_landed + B_avg_DISTANCE_att +
   B_avg_DISTANCE_landed + B_avg_opp_DISTANCE_att + B_avg_opp_DISTANCE_landed +
   B_avg_CLINCH_att + B_avg_CLINCH_landed + B_avg_opp_CLINCH_att +
   B_avg_opp_CLINCH_landed + B_total_rounds_fought + B_total_title_bouts +
    B_current_win_streak + B_current_lose_streak + B_longest_win_streak +
   B_wins + B_losses + B_Height_cms + R_Height_cms + B_Reach_cms +
    R_Reach_cms + B_avg_CONT_time_seconds + B_avg_opp_CONT_time_seconds +
    B_total_time_fought_seconds, data = RBData, family = binomial)
summary(logreg.mdl)
##
## Call:
## glm(formula = Winner ~ B_avg_KD + B_avg_opp_KD + B_avg_SIG_STR_pct +
       B_avg_opp_SIG_STR_pct + B_avg_TD_pct + B_avg_opp_TD_pct +
##
##
       B_avg_SUB_ATT + B_avg_opp_SUB_ATT + B_avg_REV + B_avg_opp_REV +
       B_avg_SIG_STR_att + B_avg_SIG_STR_landed + B_avg_opp_SIG_STR_att +
##
##
       B_avg_opp_SIG_STR_landed + B_avg_TOTAL_STR_att + B_avg_TOTAL_STR_landed +
##
       B avg opp TOTAL STR att + B avg opp TOTAL STR landed + B avg TD att +
##
       B_avg_TD_landed + B_avg_opp_TD_att + B_avg_opp_TD_landed +
##
       B_avg_HEAD_att + B_avg_HEAD_landed + B_avg_opp_HEAD_att +
##
       B_avg_opp_HEAD_landed + B_avg_BODY_att + B_avg_BODY_landed +
##
       B_avg_opp_BODY_att + B_avg_opp_BODY_landed + B_avg_DISTANCE_att +
##
       B_avg_DISTANCE_landed + B_avg_opp_DISTANCE_att + B_avg_opp_DISTANCE_landed +
##
       B_avg_CLINCH_att + B_avg_CLINCH_landed + B_avg_opp_CLINCH_att +
##
       B_avg_opp_CLINCH_landed + B_total_rounds_fought + B_total_title_bouts +
##
       B_current_win_streak + B_current_lose_streak + B_longest_win_streak +
       B_wins + B_losses + B_Height_cms + R_Height_cms + B_Reach_cms +
##
##
       R_Reach_cms + B_avg_CONT_time_seconds + B_avg_opp_CONT_time_seconds +
##
       B_total_time_fought_seconds, family = binomial, data = RBData)
##
## Deviance Residuals:
##
       Min
                     Median
                                           Max
                 10
                                   3Q
## -1.8297 -0.8835 -0.7265
                              1.2510
                                        2.4882
##
## Coefficients:
##
                                Estimate Std. Error z value Pr(>|z|)
## (Intercept)
                                2.778e-01 7.428e-01 0.374 0.708436
                               1.606e-02 9.479e-02
                                                     0.169 0.865426
## B_avg_KD
## B_avg_opp_KD
                               -1.693e-01 1.139e-01 -1.486 0.137257
## B_avg_SIG_STR_pct
                               2.218e-01 3.656e-01
                                                       0.607 0.544162
## B_avg_opp_SIG_STR_pct
                               7.449e-02 3.492e-01
                                                     0.213 0.831098
## B_avg_TD_pct
                               -4.061e-01 1.722e-01 -2.358 0.018370 *
## B_avg_opp_TD_pct
                              -7.051e-01 1.850e-01 -3.812 0.000138 ***
## B_avg_SUB_ATT
                              -5.674e-02 5.266e-02 -1.078 0.281251
## B_avg_opp_SUB_ATT
                              -1.419e-01 5.997e-02 -2.367 0.017925 *
                              -2.045e-02 1.146e-01 -0.179 0.858327
## B_avg_REV
## B_avg_opp_REV
                              -3.770e-02 1.200e-01 -0.314 0.753412
## B_avg_SIG_STR_att
                              4.543e-02 3.343e-02 1.359 0.174248
```

```
## B_avg_SIG_STR_landed
                               -5.478e-02 4.315e-02
                                                      -1.270 0.204232
                               -1.318e-01
                                           3.715e-02
                                                      -3.547 0.000390 ***
## B_avg_opp_SIG_STR_att
## B_avg_opp_SIG_STR_landed
                                1.417e-01
                                           4.700e-02
                                                        3.016 0.002565 **
## B_avg_TOTAL_STR_att
                                2.380e-03
                                           1.434e-02
                                                        0.166 0.868214
## B_avg_TOTAL_STR_landed
                               -1.198e-02
                                           1.612e-02
                                                       -0.743 0.457406
## B_avg_opp_TOTAL_STR_att
                                6.865e-02
                                           1.640e-02
                                                        4.186 2.83e-05 ***
## B_avg_opp_TOTAL_STR_landed -8.442e-02
                                           1.854e-02
                                                      -4.554 5.27e-06 ***
## B_avg_TD_att
                                5.522e-02
                                           2.271e-02
                                                        2.432 0.015032 *
## B_avg_TD_landed
                                1.234e-01
                                           5.809e-02
                                                        2.125 0.033627 *
## B_avg_opp_TD_att
                                1.796e-03
                                           2.192e-02
                                                        0.082 0.934687
## B_avg_opp_TD_landed
                                1.458e-01
                                           5.726e-02
                                                        2.547 0.010878 *
## B_avg_HEAD_att
                               -5.107e-02
                                           2.578e-02
                                                       -1.981 0.047598 *
## B_avg_HEAD_landed
                                                        2.390 0.016870 *
                                7.862e-02
                                           3.290e-02
## B_avg_opp_HEAD_att
                                           2.739e-02
                                1.055e-02
                                                        0.385 0.700008
## B_avg_opp_HEAD_landed
                               -4.091e-03
                                           3.424e-02
                                                       -0.119 0.904883
## B_avg_BODY_att
                               -2.850e-02
                                           3.108e-02
                                                       -0.917 0.359126
## B_avg_BODY_landed
                                5.482e-02
                                           3.954e-02
                                                        1.386 0.165603
## B_avg_opp_BODY_att
                                6.484e-02
                                           3.422e-02
                                                        1.895 0.058101
                                                      -1.572 0.115955
## B_avg_opp_BODY_landed
                               -6.645e-02
                                           4.227e-02
## B_avg_DISTANCE_att
                                3.157e-03
                                           1.524e-02
                                                        0.207 0.835899
## B_avg_DISTANCE_landed
                                3.988e-03
                                           2.270e-02
                                                        0.176 0.860551
## B_avg_opp_DISTANCE_att
                                4.841e-02
                                           1.630e-02
                                                        2.969 0.002983 **
## B_avg_opp_DISTANCE_landed
                                           2.372e-02
                                                      -2.114 0.034473 *
                               -5.016e-02
## B_avg_CLINCH_att
                                3.467e-03
                                           2.460e-02
                                                        0.141 0.887924
## B_avg_CLINCH_landed
                               -5.401e-03
                                           3.429e-02
                                                      -0.158 0.874821
## B_avg_opp_CLINCH_att
                                3.464e-03
                                           2.731e-02
                                                        0.127 0.899056
## B_avg_opp_CLINCH_landed
                               -4.425e-03
                                           3.770e-02
                                                      -0.117 0.906563
## B_total_rounds_fought
                                2.590e-03
                                           1.405e-02
                                                        0.184 0.853720
## B_total_title_bouts
                               -1.937e-01
                                           4.262e-02
                                                      -4.546 5.48e-06 ***
                                           3.343e-02
                                                        0.837 0.402473
## B_current_win_streak
                                2.799e-02
## B_current_lose_streak
                                4.172e-02
                                           6.095e-02
                                                        0.684 0.493680
## B_longest_win_streak
                                2.639e-02
                                           4.496e-02
                                                        0.587 0.557131
## B_wins
                               -2.438e-02
                                           4.279e-02
                                                       -0.570 0.568919
## B_losses
                                4.642e-02
                                           4.689e-02
                                                        0.990 0.322192
                               -3.443e-02
                                                       -4.440 9.00e-06 ***
## B_Height_cms
                                           7.754e-03
## R_Height_cms
                                1.376e-03
                                           7.709e-03
                                                       0.178 0.858360
## B Reach cms
                                4.813e-02
                                           6.366e-03
                                                        7.561 3.99e-14 ***
## R_Reach_cms
                               -2.312e-02
                                           6.303e-03
                                                       -3.668 0.000245 ***
## B_avg_CONT_time_seconds
                                5.945e-04
                                           5.765e-04
                                                        1.031 0.302393
## B_avg_opp_CONT_time_seconds 1.490e-03
                                                        2.536 0.011208 *
                                           5.873e-04
## B_total_time_fought_seconds 9.313e-05 3.343e-04
                                                        0.279 0.780539
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
       Null deviance: 7450.4 on 5901
                                       degrees of freedom
## Residual deviance: 7034.2 on 5849
                                       degrees of freedom
##
  AIC: 7140.2
## Number of Fisher Scoring iterations: 4
```

Usporedba modela

Sa signifikantnijim regresorima napravit ćemo samnjeni model te testirati razliku njegove i devijance početnog modela. Ukoliko devijanca nije značajno veća prihvatit ćemo smanjeni model.

```
logreg.mdl.2 = glm(Winner ~ B_avg_opp_TD_pct + B_avg_opp_SIG_STR_att +
   B_avg_opp_TOTAL_STR_att + B_avg_opp_TOTAL_STR_landed + B_total_title_bouts +
   B_Height_cms + B_Reach_cms + B_avg_opp_SIG_STR_landed + B_avg_opp_DISTANCE_att +
   R_Reach_cms + B_avg_TD_pct + B_avg_opp_SUB_ATT + B_avg_TD_att +
   B_avg_TD_landed + B_avg_opp_TD_landed + B_avg_HEAD_landed +
   B_avg_opp_DISTANCE_landed + B_avg_opp_CONT_time_seconds +
   B_avg_HEAD_att, data = RBData, family = binomial())
summary(logreg.mdl.2)
##
## Call:
## glm(formula = Winner ~ B_avg_opp_TD_pct + B_avg_opp_SIG_STR_att +
      B_avg_opp_TOTAL_STR_att + B_avg_opp_TOTAL_STR_landed + B_total_title_bouts +
##
##
      B_Height_cms + B_Reach_cms + B_avg_opp_SIG_STR_landed + B_avg_opp_DISTANCE_att +
      R_Reach_cms + B_avg_TD_pct + B_avg_opp_SUB_ATT + B_avg_TD_att +
##
      B_avg_TD_landed + B_avg_opp_TD_landed + B_avg_HEAD_landed +
##
##
      B_avg_opp_DISTANCE_landed + B_avg_opp_CONT_time_seconds +
##
      B_avg_HEAD_att, family = binomial(), data = RBData)
##
## Deviance Residuals:
##
      Min
                1Q
                     Median
                                  3Q
                                          Max
## -1.9571
           -0.8913 -0.7441
                              1.2869
                                       2.2540
##
## Coefficients:
##
                                Estimate Std. Error z value Pr(>|z|)
## (Intercept)
                               0.5081454 0.6567205
                                                      0.774 0.439071
                              -0.7113861
                                          0.1674422 -4.249 2.15e-05 ***
## B_avg_opp_TD_pct
## B_avg_opp_SIG_STR_att
                              -0.1195069
                                          0.0204092
                                                     -5.856 4.75e-09 ***
## B_avg_opp_TOTAL_STR_att
                               0.0592250 0.0149780
                                                      3.954 7.68e-05 ***
## B_avg_opp_TOTAL_STR_landed -0.0756411
                                          0.0170313 -4.441 8.94e-06 ***
                                          0.0347453 -4.490 7.13e-06 ***
## B_total_title_bouts
                              -0.1559999
                              ## B_Height_cms
## B Reach cms
                               0.0514692 0.0062504
                                                     8.235 < 2e-16 ***
## B_avg_opp_SIG_STR_landed
                               0.1386154 0.0252026
                                                     5.500 3.80e-08 ***
## B_avg_opp_DISTANCE_att
                               0.0618663
                                          0.0115417
                                                      5.360 8.31e-08 ***
## R_Reach_cms
                              -0.0229279
                                          0.0039385
                                                     -5.821 5.84e-09 ***
## B_avg_TD_pct
                              -0.4520491   0.1664566   -2.716   0.006613 **
## B_avg_opp_SUB_ATT
                              -0.1207523
                                          0.0558293 -2.163 0.030550 *
## B_avg_TD_att
                               0.0445217
                                          0.0210792
                                                      2.112 0.034676 *
                               0.1246005 0.0537836
## B_avg_TD_landed
                                                      2.317 0.020520 *
## B_avg_opp_TD_landed
                               0.1558475
                                          0.0430320
                                                      3.622 0.000293 ***
## B_avg_HEAD_landed
                               0.0100845
                                          0.0048285
                                                      2.089 0.036750 *
## B_avg_opp_DISTANCE_landed
                              -0.0628479
                                          0.0170008
                                                     -3.697 0.000218 ***
## B_avg_opp_CONT_time_seconds 0.0014172
                                          0.0004674
                                                      3.032 0.002430 **
## B avg HEAD att
                               0.0008153 0.0022118
                                                      0.369 0.712399
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
```

```
##
##
       Null deviance: 7450.4 on 5901 degrees of freedom
## Residual deviance: 7097.1 on 5882 degrees of freedom
## AIC: 7137.1
## Number of Fisher Scoring iterations: 4
anova(logreg.mdl, logreg.mdl.2, test = "LRT")
## Analysis of Deviance Table
## Model 1: Winner ~ B_avg_KD + B_avg_opp_KD + B_avg_SIG_STR_pct + B_avg_opp_SIG_STR_pct +
##
       B_avg_TD_pct + B_avg_opp_TD_pct + B_avg_SUB_ATT + B_avg_opp_SUB_ATT +
       B_avg_REV + B_avg_opp_REV + B_avg_SIG_STR_att + B_avg_SIG_STR_landed +
##
##
       B_avg_opp_SIG_STR_att + B_avg_opp_SIG_STR_landed + B_avg_TOTAL_STR_att +
##
       B_avg_TOTAL_STR_landed + B_avg_opp_TOTAL_STR_att + B_avg_opp_TOTAL_STR_landed +
##
       B_avg_TD_att + B_avg_TD_landed + B_avg_opp_TD_att + B_avg_opp_TD_landed +
##
       B_avg_HEAD_att + B_avg_HEAD_landed + B_avg_opp_HEAD_att +
       B_avg_opp_HEAD_landed + B_avg_BODY_att + B_avg_BODY_landed +
##
##
       B_avg_opp_BODY_att + B_avg_opp_BODY_landed + B_avg_DISTANCE_att +
##
       B_avg_DISTANCE_landed + B_avg_opp_DISTANCE_att + B_avg_opp_DISTANCE_landed +
##
       B_avg_CLINCH_att + B_avg_CLINCH_landed + B_avg_opp_CLINCH_att +
##
       B_avg_opp_CLINCH_landed + B_total_rounds_fought + B_total_title_bouts +
##
       B_current_win_streak + B_current_lose_streak + B_longest_win_streak +
##
       B_wins + B_losses + B_Height_cms + R_Height_cms + B_Reach_cms +
##
       R_Reach_cms + B_avg_CONT_time_seconds + B_avg_opp_CONT_time_seconds +
       B_total_time_fought_seconds
##
## Model 2: Winner ~ B_avg_opp_TD_pct + B_avg_opp_SIG_STR_att + B_avg_opp_TOTAL_STR_att +
##
       B_avg_opp_TOTAL_STR_landed + B_total_title_bouts + B_Height_cms +
##
       B_Reach_cms + B_avg_opp_SIG_STR_landed + B_avg_opp_DISTANCE_att +
##
       R_Reach_cms + B_avg_TD_pct + B_avg_opp_SUB_ATT + B_avg_TD_att +
##
       B_avg_TD_landed + B_avg_opp_TD_landed + B_avg_HEAD_landed +
##
       B_avg_opp_DISTANCE_landed + B_avg_opp_CONT_time_seconds +
##
       B_avg_HEAD_att
##
     Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1
          5849
                   7034.2
          5882
                   7097.1 -33 -62.801 0.001331 **
## 2
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
Razlika u devijancama modela je značajna, tako da nećemo moći koristiti ovaj smanjeni model kao substituciju
za primarni. (p - vrijednost = 0.001331)
Izračunajmo matricu zabune za originalni model
Stvarno/Opaženo (pobjeda) Y=0 Y=1 Y=0 TN FP Y=1 FN TP
yHat <- logreg.mdl$fitted.values > 0.5
tab <- table(RBData$Winner, yHat)</pre>
tab
##
      yHat
##
       FALSE TRUE
##
       3711
              268
```

1614 309

##

```
accuracy = sum(diag(tab))/sum(tab)
precision = tab[2, 2]/sum(tab[, 2])
recall = tab[2, 2]/sum(tab[2, ])
specificity = tab[1, 1]/sum(tab[, 1])

print(pasteO("Točnost: ", accuracy)) # Udio točno pretostavljenih pobjednika i gubitnika (TP+TN)/(TP+

## [1] "Točnost: 0.681125042358523"

print(pasteO("Preciznost: ", precision)) # Udio točno pretostavljenih pobjednika u onima koji su klasi

## [1] "Preciznost: 0.535528596187175"

print(pasteO("Odziv: ", recall)) # Udio točno pretostavljenih pobjednika u skupu svih koji su stvarno

## [1] "Odziv: 0.160686427457098"

print(pasteO("Specifičnost: ", specificity)) # Udio točno pretostavljenih gubitnika u skupu svih koji

## [1] "Specifičnost: 0.696901408450704"
```

Zaključak

Po danim značajkama možemo u 68% slučajeva točno pretpostaviti pobjednika i gubitnika. U značajnom broju slučajeva borca koji je pobjedio proglašavamo gubitnikom.

Možemo vidjeti da udio pravih pobjednika u skupu onih za koje smo pretpostavili da će pobjediti 53.5%, te time ne možemo sa sigurnošću zaključiti tko će pobjediti samo na osnovi danih podataka iz prijašnjih borba. Iako ove varijable mogu pripomoći predvidjeti pobjednika, to se predviđanje po danim podatcima borca ne može sa sigurnošću potvrditi.